

پروژه تحلیل داده

تحلیل رگرسیون خطی (OLS)

کاربرد داده‌های واقعی در بررسی روابط اقتصادی و اجتماعی

آیلین رحمانی پور

تحلیل و مدل‌سازی با نرم‌افزار R

درباره پروژه

این گزارش، سه مطالعه‌ی مستقل رگرسیونی را ارائه می‌دهد که با استفاده از روش کمترین مربعات معمولی (OLS) و در محیط R انجام شده‌اند. هدف از هر مطالعه، بررسی یک رابطه‌ی اقتصادی یا اجتماعی مشخص، برازش مدل مناسب، ارزیابی معناداری آماری و تفسیر نتایج است. در ادامه، سه بخش زیر به ترتیب ارائه می‌شوند:

- رابطه‌ی بین رشد اقتصادی و رشد اشتغال در ۳۱ کشور عضو OECD
- رابطه‌ی ثروت ملی و نابرابری درآمد با میزان عدم تحمل اجتماعی در سطح بین‌کشوری
- اثر درآمد خانوار بر مشارکت در رأی‌گیری، با استفاده از داده‌های نظرسنجی جمعیت آمریکا (CPS ۲۰۱۸)

۱. رشد اشتغال و رشد تولید ناخالص داخلی (کشورهای OECD)

داده‌های این بخش شامل نرخ رشد سالانه‌ی اشتغال (Employment) و نرخ رشد تولید ناخالص داخلی واقعی (GDP) برای ۳۱ کشور عضو OECD طی دوره‌ی ۲۰۰۲ تا ۲۰۰۷ است. هدف، بررسی این پرسش است که آیا رشد اقتصادی با رشد اشتغال رابطه دارد، و در صورت وجود رابطه، این اثر تا چه اندازه معنادار و قابل‌اتکاست.

۱.۱ مدل و برازش در R

مدل رگرسیون خطی ساده‌ی زیر برازش داده شد:

$$Employment_i = \theta_0 + \theta_1 \cdot GDP_i + u_i$$

```
data <- data.frame(
  Country = c("Australia", "Austria", ..., "UK", "USA"), # 31 OECD countries
  Employment = c(2.57, 1.64, 1.06, ..., 0.92, 1.36),
  GDP = c(3.52, 2.66, 2.27, ..., 3.31, 2.88)
)

model <- lm(Employment ~ GDP, data = data)
summary(model)
```

۱.۲ خروجی مدل

متغیر	برآورد ضریب	خطای استاندارد	آماره t	مقدار p
(Intercept)	0.4920	0.2833	1.737	0.093
GDP	0.2379	0.0703	3.387	0.0021

$R^2 = 0.2834$ | R^2 تعدیل‌شده = ۰.۲۵۸۷ | خطای استاندارد باقیمانده = ۰.۶۶۹۲ روی ۲۹ درجه آزادی

آماره F = ۱۱.۴۷ روی (۱، ۲۹) درجه آزادی، p-value = ۰.۰۰۲۰۵

۱.۳ محاسبه‌ی دستی ضرایب

برای اطمینان از صحت خروجی نرم افزار، ضرایب با استفاده از مقادیر خلاصه‌ی زیر به صورت دستی محاسبه شدند:

$$\begin{aligned}\bar{e} &= 1.3603 & \bar{g} &= 3.6508 \\ \Sigma(e_i - \bar{e})(g_i - \bar{g}) &= 21.5935 & \Sigma(g_i - \bar{g})^2 &= 90.7639 & n &= 31 \\ \beta_1 &= \Sigma(e_i - \bar{e})(g_i - \bar{g}) / \Sigma(g_i - \bar{g})^2 = 21.5935 / 90.7639 = 0.2379 \\ \beta_0 &= \bar{e} - \beta_1 \bar{g} = 1.3603 - 0.2379 \times 3.6508 = 0.4917\end{aligned}$$


مقادیر به دست آمده ($\beta_0 = 0.4917$ و $\beta_1 = 0.2379$) عملاً با خروجی تابع lm در R (به ترتیب 0.492 و 0.238) برابرند؛ اختلاف جزئی صرفاً ناشی از گرد شدن اعداد در محاسبه‌ی دستی است.

۱.۴ معادله‌ی رگرسیون و تفسیر ضرایب

$$\text{Employment} = 0.492 + 0.238 \times \text{GDP}$$

- شیب ($\beta_1 = 0.238$): با افزایش یک واحد درصدی در نرخ رشد GDP، به طور متوسط نرخ رشد اشتغال حدود 0.238 واحد درصد افزایش می‌یابد. این ضریب در سطح خطای 5٪ معنادار است ($p = 0.002$).
- عرض از مبدأ ($\beta_0 = 0.492$): مقدار پیش‌بینی‌شده‌ی رشد اشتغال در حالت فرضی $\text{GDP} = 0$ است؛ از نظر اقتصادی تفسیر مستقیمی ندارد، اما برای برازش صحیح مدل لازم است. این ضریب در سطح 5٪ معنادار نیست ($p = 0.093$).

Employment growth vs real GDP growth



نمودار پراکنش رشد اشتغال در برابر رشد GDP به همراه خط برازش OLS

شیب مثبت خط رگرسیون، رابطه‌ی مثبت بین GDP و اشتغال را تأیید می‌کند. پراکندگی نسبی نقاط حول خط نشان می‌دهد GDP به تنهایی توضیح‌دهنده‌ی کامل تغییرات اشتغال نیست و عوامل دیگری نیز نقش دارند؛ این موضوع با مقدار نسبتاً پایین R^2 سازگار است. الگوی سیستماتیک خاصی در پراکندگی باقیمانده‌ها دیده نمی‌شود و شواهدی از مشاهدات پرت (outlier) برجسته وجود ندارد.

۱.۵ ضریب تعیین (R^2)

مقدار R^2 برابر با 0.283 است؛ یعنی حدود 28.3٪ از تغییرات نرخ رشد اشتغال میان کشورها توسط تغییرات نرخ رشد GDP توضیح داده می‌شود. اگرچه رابطه مثبت و معنادار است، بخش قابل توجهی از تغییرات اشتغال همچنان توسط عوامل خارج از مدل تبیین می‌شود.

۱.۶ آزمون فرض برای ضریب شیب

- فرض صفر: $H_0: \beta_1 = 0$ (بدون رابطه‌ی خطی بین GDP و اشتغال)

- فرض مقابل: $H_1: \beta_1 \neq 0$

$$SE(\beta_1) = \sqrt{\sigma^2 / \sum (g_i - \bar{g})^2} \rightarrow t = \beta_1 / SE(\beta_1) = 3.387$$

$$t_{critical}(\alpha=0.05, df=29) = 2.045$$

چون $|t| = 3.387$ بزرگ‌تر از مقدار بحرانی 2.045 است، فرض صفر در سطح اطمینان 95% رد می‌شود؛ نتیجه می‌گیریم نرخ رشد GDP اثر معناداری بر نرخ رشد اشتغال دارد.

۱.۷ مقدار p و فاصله اطمینان 95% برای شیب

مقدار p برای ضریب GDP برابر 0.00205 است؛ یعنی احتمال مشاهده‌ی چنین رابطه‌ای (یا قوی‌تر) در صورت درست بودن فرض صفر، بسیار پایین است — همان نتیجه‌ای که آزمون t نیز نشان داد.

$$95\% CI(\beta_1) = 0.238 \pm 2.045 \times 0.0703 = [0.0943, 0.3816]$$

چون صفر درون این بازه قرار ندارد، اثر GDP بر اشتغال با اطمینان 95% مثبت و معنادار ارزیابی می‌شود.

۲. عوامل اقتصادی-اجتماعی و عدم تحمل ملی


در این بخش، رابطه‌ی بین دو شاخص اقتصادی — ثروت سرانه و نابرابری درآمد — با شاخص ترکیبی عدم تحمل اجتماعی (n_sum ، برآمده از چهار سنج‌های عدم تحمل نسبت به نژاد، مهاجرت، مذهب و زبان) در سطح کشورها بررسی می‌شود.

۲.۱ آیا کشورهای ثروتمندتر، متحمل‌تر هستند؟

```
model_rich <- lm(n_sum ~ gdpcap, data = data_intol)
summary(model_rich)
```

متغیر	برآورد ضریب	خطای استاندارد	آماره t	مقدار p
(Intercept)	0.8984	0.0840	10.70	<0.001
gdpcap	-0.0075	0.0035	-2.15	0.0359

$R^2 = 0.0762$ R^2 تعدیل‌شده = 0.0597 خطای استاندارد باقیمانده = 0.482 روی 56 درجه آزادی



ثروت ملی (GDP سرانه) در برابر شاخص عدم تحمل، با خط رگرسیون و برجسب نام کشورها

رابطه‌ی بین GDP سرانه و شاخص عدم تحمل منفی و از نظر آماری معنادار است ($\beta_1 = -0.0075$, $p = 0.036$): به ازای هر واحد افزایش در GDP سرانه، شاخص عدم تحمل به طور متوسط 0.0075 واحد کاهش می‌یابد؛ یعنی کشورهای ثروتمندتر عموماً متحمل‌تر هستند. با این حال $R^2 = 0.076$ نشان می‌دهد تنها حدود 7.6% از تغییرات عدم تحمل میان کشورها با ثروت ملی توضیح داده می‌شود.


مشاهده‌ی پرت: بر اساس باقیمانده‌های استاندارد شده (rstandard)، لیبی (GDP سرانه = 7.65 ، $n_sum = 2.08$) با فاصله‌ی قابل توجهی از الگوی کلی قرار دارد — کشوری نسبتاً فقیر اما با سطح عدم تحمل پایین‌تر از حد پیش‌بینی مدل.

۲.۲ آیا کشورهای نابرابرتر، کم‌تحمل‌تر هستند؟

```
model_ineq <- lm(n_sum ~ gini, data = data_intol)
summary(model_ineq)
```

متغیر	برآورد ضریب	خطای استاندارد	آماره t	مقدار p
(Intercept)	1.3657	0.3143	4.345	<0.001
gini	-0.0157	0.0081	-1.923	0.0601

$R^2 = 0.0676$ R^2 تعدیل شده = 0.0493 خطای استاندارد باقیمانده = 0.467 روی 51 درجه آزادی (۵ مشاهده حذف شده به دلیل داده گمشده)



ضریب جینی (ناابرابری درآمد) در برابر شاخص عدم تحمل، با خط رگرسیون و برچسب نام کشورها

برخلاف انتظار، رابطه‌ی مشاهده‌شده بین نابرابری درآمد و عدم تحمل ضعیف و منفی است ($\beta = -0.0157$) و در سطح متعارف ۵٪ معنادار نیست ($p = 0.060$)، هرچند به آستانه‌ی معناداری نزدیک است. ضریب جینی تنها حدود ۶.۸٪ از تغییرات عدم تحمل را توضیح می‌دهد؛ نتیجه‌ی غیرمنتظره احتمالاً ناشی از عوامل مداخله‌گر یا محدودیت حجم داده (۵ مشاهده گمشده) است. بررسی باقیمانده‌های استانداردشده مشاهده‌ی پرت قابل توجهی نشان نداد.

۳. درآمد خانوار و مشارکت در رأی‌گیری (CPS نوامبر ۲۰۱۸)

این بخش با استفاده از داده‌های ضمیمه‌ی رأی‌گیری در نظرسنجی جمعیت آمریکا (Current Population Survey) بررسی می‌کند که آیا خانوارهای پردرآمدتر، احتمال بیشتری برای رأی دادن دارند.

۳.۱ آماده‌سازی داده

- متغیر وابسته: `voted01` — بازکدگذاری متغیر اصلی `voted` به صورت ۰ (رأی نداده) و ۱ (رأی داده)؛ سایر پاسخ‌ها گمشده در نظر گرفته شدند.
- متغیر مستقل: `faminc_mid`. بازکدگذاری متغیر رتبه‌ای درآمد خانوار (`faminc`) به مقدار فاصله‌ای، با جایگزینی هر بازه با نقطه‌ی میانی آن (مثلاً بازه‌ی ۵۰۰۰ تا ۷۵۰۰ دلار → ۶۲۵۰ دلار).

```
data_cps$voted01 <- NA
data_cps$voted01[data_cps$voted == 2] <- 1 # voted
data_cps$voted01[data_cps$voted == 1] <- 0 # did not vote

data_cps <- data_cps %>% mutate(faminc_mid = case_when(
  faminc == 100 ~ 2500, faminc == 210 ~ 6250, ...,
  faminc == 843 ~ 200000, TRUE ~ NA_real_
))
```

۳.۲ مدل اول — رابطه‌ی خطی (Model I)

$$\text{voted01} = \alpha + \beta \cdot \text{faminc_mid} + u$$

```
model_I <- lm(voted01 ~ faminc_mid, data = data_cps)
```


متغیر	برآورد ضریب	خطای استاندارد	آماره t	مقدار p
(Intercept)	0.5376	0.0300	17.92	<0.001
faminc_mid	1.37e-06	2.95e-07	4.629	<0.001

$R^2 = 0.0297$ $R^2_{\text{تعدیل شده}} = 0.0283$ $n = 702$ (۵۳۳ مشاهده به دلیل داده گمشده حذف شد)


آماره $F = 21.42$ روی (۱، ۷۰۰) درجه آزادی، $AIC = 938.04$ | $p\text{-value} = 4.4e-06$

درآمد خانوار رابطه‌ای مثبت و از نظر آماری معنادار با مشارکت در رأی‌گیری دارد: به ازای هر ۱۰۰۰ دلار افزایش در درآمد، احتمال رأی دادن حدود ۰.۰۱۴ افزایش می‌یابد. عرض از مبدأ (۰.۵۳۸) نشان می‌دهد یک خانواده‌ی فرضی با درآمد صفر حدود ۵۳.۸٪ احتمال رأی دادن دارد. $R^2 = 0.030$ نشان می‌دهد درآمد به تنهایی تنها حدود ۳٪ از تغییرات رفتار رأی‌دهی را توضیح می‌دهد.

بررسی مفروضه‌ی خطی بودن رابطه



بررسی خطی بودن رابطه: برازش خطی (قرمز) در برابر برازش انعطاف‌پذیر لوس (آبی)



نمودار باقیمانده‌ها در برابر مقادیر برازش‌شده برای مدل خطی

مقایسه‌ی خط برازش خطی با منحنی انعطاف‌پذیر (loess) نشان می‌دهد فرض خطی بودن به‌طور کامل برقرار نیست: در سطوح پایین درآمد شیب اثر تندتر و در سطوح بالای درآمد کندتر است — نشانه‌ای از بازدهی نزولی. این الگو استفاده از یک تبدیل غیرخطی مانند لگاریتم را توجیه می‌کند.


۳.۳ مدل دوم — تبدیل لگاریتمی درآمد (Model II)

$$voted01 = \alpha + \beta \cdot \log(faminc_mid) + u$$

```
data_cps <- data_cps %>% mutate(log_faminc = log(faminc_mid))
model_II <- lm(voted01 ~ log_faminc, data = data_cps)
```

متغیر	برآورد ضریب	خطای استاندارد	آماره t	مقدار p
(Intercept)	-0.4410	0.2124	-2.076	0.0382
log_faminc	0.0993	0.0193	5.152	<0.001

$R^2 = 0.0365$ R^2 تعدیل‌شده = 0.0352 AIC = 933.07



مقایسه‌ی مدل خطی (چپ) و مدل با تبدیل لگاریتمی درآمد (راست)

مقایسه‌ی دو مدل

معیار	Model I (خطی)	Model II (لگاریتمی)
R^2	0.0297	0.0365
R^2 تعدیل شده	0.0283	0.0352
AIC	938.04	933.07

مدل دوم با تبدیل لگاریتمی درآمد، رابطه‌ای مثبت و معنادار نشان می‌دهد ($\beta = 0.099, p < 0.001$): با دو برابر شدن درآمد خانوار، احتمال رأی دادن حدود ۶.۹ درصد افزایش می‌یابد — تفسیری که بازدهی نزولی درآمد را به‌خوبی منعکس می‌کند. مدل دوم برازش بهتری نیز دارد: R^2 از ۰.۰۳۰ به ۰.۰۳۷ و AIC از ۹۳۸.۰۴ به ۹۳۳.۰۷ کاهش یافته است.